

Aprendizado por Reforço no Dilema do Prisioneiro Iterado: Emergência de Cooperação em Agentes Q-Learning Multi-Agente

Estudo computacional com análise estatística inferencial

Maio de 2026

Resumo

Este artigo apresenta um estudo empírico e estatisticamente rigoroso sobre a **emergência de comportamento cooperativo** em agentes dotados de Aprendizado por Reforço (Q-Learning tabular) que interagem no **Dilema do Prisioneiro Iterado (DPI)**. Foram conduzidos cinco experimentos fatoriais ($n=30$ sementes, $T=2.000$ rodadas cada), variando o tipo de oponente, o nível de ruído e a profundidade de memória dos agentes. Os resultados mostram que agentes Q-Learning convergem para o equilíbrio de Nash de traição mútua em confrontos simétricos, mas aprendem cooperação elevada (72%) quando opostos ao Tit-for-Tat. A análise de Kruskal-Wallis confirmou diferença global entre condições ($H=125,12$; $p<0,001$). O tipo de oponente mostrou-se o principal determinante da cooperação aprendida ($r=1,0$), enquanto profundidade de memória não produziu efeito significativo ($d=-0,057$; $p=0,826$). O código completo e o notebook Jupyter estão disponíveis no repositório GitHub.

Palavras-chave: Dilema do Prisioneiro Iterado, Q-Learning, Aprendizado por Reforço Multi-Agente, Teoria dos Jogos, Emergência de Cooperação.

1. Introdução

A teoria dos jogos, ramo da matemática aplicada e da economia, estuda situações em que o resultado de uma decisão depende não apenas das próprias escolhas, mas também das escolhas de outros agentes. Desde os trabalhos de von Neumann e Morgenstern na década de 1940 e de Nash na década de 1950, ela se tornou uma das ferramentas analíticas mais poderosas nas ciências sociais, biológicas e computacionais.

No centro da teoria dos jogos está o conceito de Equilíbrio de Nash: um perfil de estratégias no qual nenhum jogador tem incentivo unilateral para se desviar, dado o comportamento dos demais. Em muitos jogos, esse equilíbrio é único e trivial de calcular. Mas em certos jogos socialmente relevantes, o equilíbrio é paradoxalmente ineficiente: todos os jogadores ficam piores do que ficariam se cooperassem.

O Dilema do Prisioneiro (DP) é o exemplo mais famoso desse fenômeno. Formulado originalmente por Merrill Flood e Melvin Dresher em 1950 e nomeado por Albert Tucker, o DP

captura uma tensão fundamental: o interesse individual racional leva a um resultado coletivamente ruim. Na versão iterada do jogo (DPI), o horizonte repetido abre espaço para estratégias de reciprocidade, reputação e punição, tornando a cooperação possível é, em certas condições, evolutivamente estável.

Com o advento do Aprendizado por Reforço (AR), surge uma pergunta natural: agentes que aprendem por tentativa e erro, sem conhecimento prévio das regras do jogo, conseguem descobrir a cooperação? Este artigo investiga essa questão de forma empírica e rigorosa, utilizando agentes Q-Learning no DPI e analisando estatisticamente os resultados de cinco condições experimentais.

2. Fundamentos de Teoria dos Jogos

2.1 O que é Teoria dos Jogos?

Teoria dos Jogos é o estudo matemático de situações de decisão estratégica, onde o resultado para cada participante depende das ações de todos os envolvidos. Um jogo é definido por três elementos: (i) um conjunto de jogadores; (ii) um conjunto de estratégias disponíveis para cada jogador; e (iii) uma função de payoff que mapeia perfis de estratégias a resultados.

Os jogos podem ser cooperativos ou não-cooperativos, de soma zero ou não, com informação completa ou incompleta, estáticos ou dinâmicos. O DPI pertence a categoria dos jogos não cooperativos, não-soma zero e de informação completa.

2.2 O Dilema do Prisioneiro

O DPI é um jogo de dois jogadores. Cada jogador escolhe simultaneamente entre duas ações: Cooperar (C) ou Trair (D, de Defect em inglês). Os payoffs são definidos pela seguinte lógica:

- Se ambos cooperam, cada um recebe R (recompensa pela cooperação mútua). Aqui, $R = 3$.
- Se ambos traem, cada um recebe P (punição pela traição mútua). Aqui, $P = 1$.
- Se um coopera e o outro trai, o traidor recebe T (tentação) e o cooperador recebe S (lesado). Aqui, $T = 5$ e $S = 0$.

A condição $T > R > P > S$ garante o dilema: trair é sempre a estratégia dominante (qualquer que seja a ação do oponente, D dá um payoff maior), mas a traição mútua (P, P) é pior que a cooperação mútua (R, R). O equilíbrio de Nash do jogo estático é (D, D) — um resultado subótimo para ambos.

2.3 O Dilema Iterado e a Emergência de Cooperação

Quando o jogo é repetido por T rodadas (DPI), a situação muda radicalmente. Com horizonte finito é conhecido, o argumento de indução retroativa ainda leva a traição em todas as rodadas. Mas com horizonte indeterminado ou descontado, o folk theorem da teoria dos jogos garante que a cooperação pode ser sustentada em equilíbrio, desde que o fator de desconto gamma seja suficientemente alto:

$$\gamma \geq (T - R) / (T - P)$$

No torneio computacional de Robert Axelrod (1984), estratégias de vários pesquisadores competiram no DPI. A vencedora foi o Tit-for-Tat (TFT): coopera na primeira rodada e depois replica exatamente a última ação do oponente. TFT é simples, amigável (nunca trai primeiro), retaliadora (pune traição imediatamente) e perdoadora (volta a cooperar se o oponente cooperar). Esse resultado moldou décadas de pesquisa em cooperação evolutiva, biologia, economia e ciência política.

2.4 Aplicações Reais da Teoria dos Jogos

O DPI não é apenas um experimento mental. Ele modela uma ampla variedade de situações reais:

- Corridas armamentistas entre nações (ambas preferem desarmar, mas cada uma teme ser a única desarmada)
- Cartelização de preços (empresas ganham mais cooperando, mas cada uma tem incentivo de cortar preço)
- Dilemas de saúde pública como vacinação (o indivíduo prefere não se vacinar se todos os outros se vacinarem)
- Negociações comerciais e acordos climáticos internacionais
- Design de protocolos de segurança em redes distribuídas

3. Aprendizado por Reforço e Q-Learning

3.1 O Paradigma do Aprendizado por Reforço

Aprendizado por Reforço (AR) é um paradigma de aprendizado de máquina em que um agente aprende a tomar decisões interagindo com um ambiente. A cada passo, o agente observa o estado do ambiente, escolhe uma ação, recebe uma recompensa e transita para um novo estado. O objetivo é aprender uma política que maximize a recompensa acumulada ao longo do tempo.

Diferentemente do aprendizado supervisionado, o agente não recebe exemplos de ações corretas: ele descobre o que funciona através de tentativa e erro. Isso torna o AR especialmente adequado para modelar agentes que aprendem a jogar jogos sem conhecimento prévio das regras ou estratégias ótimas.

3.2 Q-Learning

Q-Learning, proposto por Watkins em 1989, é um algoritmo de diferença temporal que aprende a função de valor-ação $Q(s, a)$ — o valor esperado de tomar ação a no estado s e depois seguir a política ótima. A regra de atualização é:

$$Q(s, a) \leftarrow Q(s, a) + \alpha * [r + \gamma * \max_{a'} Q(s', a') - Q(s, a)]$$

onde α é a taxa de aprendizado, γ o fator de desconto, r a recompensa imediata e s' o próximo estado. O termo entre colchetes é o erro de diferença temporal (TD error): a diferença entre o valor estimado atual e o valor alvo.

A escolha de ações segue a política epsilon-greedy: com probabilidade epsilon, o agente explora (escolhe uma ação aleatória); com probabilidade $1 - \epsilon$, ele explota (escolhe a ação com maior Q-valor). Ao longo do treinamento, epsilon decai exponencialmente, transitando de exploração pura para exploração quase total.

3.3 Q-Learning no DPI

Para aplicar Q-Learning ao DPI, é necessário definir o espaço de estados. Aqui, o estado é representado pelo histórico das últimas k interações: os pares (minha_ação, ação_oponente) das k rodadas anteriores. Com $k=1$, há $|S| = 4$ estados (CC, CD, DC, DD). Com $k=2$, há $|S| = 16$ estados. A Q-table tem dimensão $|S| \times 2$.

O cenário MARL (Multi-Agent Reinforcement Learning) surge quando ambos os jogadores são agentes Q-Learning que aprendem simultaneamente. Isso cria um ambiente não-estacionário: enquanto o agente A aprende, o comportamento do agente B muda, e vice-versa. Essa não-estacionariedade é uma das principais dificuldades teóricas do MARL.

4. Metodologia

4.1 Design Experimental

Foram conduzidos cinco experimentos fatoriais para investigar como diferentes condições afetam a cooperação aprendida. Cada experimento foi replicado com 30 sementes independentes, totalizando 150 simulações. Cada simulação executou 2.000 rodadas.

Experimento	Agente A	Agente B	Memória k	Ruído sigma
Exp. 1 (base)	Q-Learning	Q-Learning	1	0%
Exp. 2 (ruído)	Q-Learning	Q-Learning	1	5%
Exp. 3 (memória)	Q-Learning	Q-Learning	2	0%
Exp. 4 (TFT)	Q-Learning	Tit-for-Tat	1	0%
Exp. 5 (AIID)	Q-Learning	Sempre-Trair	1	0%

Tabela 1. Design experimental: cinco condições, $n=30$ sementes cada.

4.2 Hiperparâmetros

Os hiperparâmetros do agente Q-Learning foram definidos com base em práticas consolidadas da literatura de AR:

Parâmetro	Símbolo	Valor	Justificativa
Taxa de aprendizado	alpha	0,10	Convergência moderada, sem overshooting

Fator de desconto	gamma	0,95	Valoriza futuro próximo; favorece reciprocidade
Epsilon inicial	epsilon_0	1,00	Exploração total no início
Decaimento de epsilon	decay	0,9995	Convergência em aprox. 3.000 passos
Epsilon mínimo	epsilon_min	0,01	Exploração residual evita determinismo

Tabela 2. Hiperparâmetros dos agentes Q-Learning.

4.3 Metricas

A métrica principal é a taxa de cooperação na fase final (TCF): a proporção de ações C nas últimas 500 rodadas. Complementarmente, analisa-se a pontuação total acumulada e a curva de cooperação suavizada (media movel de 100 rodadas) ao longo do treinamento.

4.4 Análise Estatística

Dado que a normalidade das amostras não é garantida, adotou-se abordagem não-paramétrica. O teste de Kruskal-Wallis avaliou diferenças globais entre condições. Comparações par a par foram realizadas com Mann-Whitney U, com correção de Bonferroni para controle do erro tipo I ($\alpha = 0,05$). O tamanho de efeito foi estimado pela correlação rank-biserial r . Para o efeito da memória, aplicou-se o teste t independente com d de Cohen. A convergência das curvas foi testada com t pareado comparando fase inicial (rodadas 500-1000) versus fase tardia (1500-2000).

5. Resultados

5.1 Estatísticas Descritivas

Condicao	Media	Desvio Padrao	Mediana	IC 95% inf	IC 95% sup
QL x QL, k=1, sigma=0%	0,219	0,016	0,217	0,214	0,225
QL x QL, k=1, sigma=5%	0,244	0,015	0,243	0,238	0,249
QL x QL, k=2, sigma=0%	0,218	0,020	0,215	0,211	0,225
QL x TFT, k=1, sigma=0%	0,724	0,111	0,775	0,684	0,764
QL x AIID, k=1, sigma=0%	0,105	0,010	0,103	0,101	0,108

Tabela 3. Estatísticas descritivas da taxa de cooperação na fase final (últimas 500 rodadas). $n=30$ sementes por condição.

A condição QL x TFT produziu a maior taxa de cooperação media ($M=0,724$; $DP=0,111$), seguida por QL x QL com ruído ($M=0,244$). A condição QL x AIID resultou na menor cooperação ($M=0,105$), demonstrando que em ambiente hostil o agente aprende corretamente a trair. Em

confrontos simétricos sem ruído, a cooperação converge para valores baixos ($M=0,219$), próximos ao equilíbrio de Nash do jogo estático.

5.2 Curvas de Aprendizado




Figura 1. Evolução da taxa de cooperação ao longo das rodadas para os cinco experimentos. Linha contínua = média sobre $n=30$ sementes; área sombreada = intervalo de confiança de 95%. Linha tracejada cinza = limiar de 50%.

As curvas revelam padrões qualitativamente distintos por condição. Em QL x QL (Exp. 1 e 3), a cooperação parte de aproximadamente 50% -- reflexo da fase de exploração aleatória com $\epsilon=1$ -- e decresce monotonicamente à medida que ϵ decai, convergindo para traição. Em QL x TFT (Exp. 4), observa-se alta variância inicial seguida de bifurcação: parte das sementes converge para alta cooperação, enquanto outras ficam presas em ciclos de retaliação. Em QL x AIID (Exp. 5), a convergência para traição é rápida e uniforme.

Testes t pareados confirmaram estacionariedade estatística na fase final: Exp. 1 ($t=18,81$; $p<0,001$) e Exp. 3 ($t=20,64$; $p<0,001$), indicando que os agentes convergiram antes das últimas 500 rodadas.

5.3 Análise Inferencial




Figura 2. Distribuição da cooperação final (esquerda) e da pontuação total (direita) por condição. Boxplots com entalhe = IC 95% da mediana.

O teste de Kruskal-Wallis rejeitou a hipótese nula de igualdade entre condições ($H=125,12$; $p<0,001$), confirmando que ao menos uma condição difere significativamente das demais.

Par de condições	p (Bonferroni)	r (efeito)	Significativo?
QL x QL k=1 vs QL x QL ruído	1,66e-05	0,721	Sim
QL x QL k=1 vs QL x QL k=2	1,000	-0,040	Não
QL x QL k=1 vs QL x TFT	3,01e-10	1,000	Sim
QL x QL k=1 vs QL x AIID	2,99e-10	-1,000	Sim
QL x QL ruído vs QL x TFT	3,00e-10	1,000	Sim
QL x QL ruído vs QL x AIID	2,98e-10	-1,000	Sim
QL x QL k=2 vs QL x TFT	3,01e-10	1,000	Sim
QL x AIID vs QL x TFT	2,98e-10	-1,000	Sim

Tabela 4. Comparações post-hoc Mann-Whitney com correção de Bonferroni. r: correlação rank-biserial (grande efeito quando $|r| > 0,5$).

Todas as comparações envolvendo tipo de oponente distinto foram significativas com efeito máximo ($|r|=1,0$). A única comparação não-significativa foi k=1 versus k=2 ($p=1,0$; $r=-0,04$), indicando que o aumento de memória não influencia a taxa de cooperação final na faixa estudada.

5.4 Q-Table, Efeito de Memória e Sensibilidade de Hiperparâmetros




Figura 3. (Esquerda) Q-Table aprendida por um agente representativo ($k=2$, 5.000 rodadas): valores maiores na coluna D indicam preferência por traição na maioria dos estados. (Centro) Distribuição da cooperação final para $k=1$ versus $k=2$ ($d=-0,057$; não significativo). (Direita) Curva de decaimento de epsilon ao longo do treinamento.

A inspeção da Q-table revela que, após convergência, a maioria dos estados apresenta $Q(s,D) > Q(s,C)$, refletindo a aprendizagem da estratégia dominante do jogo estático. A diferença entre $k=1$ e $k=2$ é estatisticamente nula (d de Cohen = $-0,057$; $t=0,22$; $p=0,826$), sugerindo que, no DPI com oponente simétrico, memória adicional não altera o equilíbrio aprendido.




Figura 4. Mapa de calor da taxa de cooperação final em função da taxa de aprendizado (α) e do fator de desconto (γ). Verde = alta cooperação; vermelho = baixa cooperação. $n=10$ sementes por célula, 1.000 rodadas.

O mapa de calor evidencia uma interação entre α e γ : valores altos de γ (agente que valoriza o futuro) tendem a produzir maior cooperação, especialmente com α moderado (0,1-0,2). Valores extremos de α (0,4) com γ alto provocam instabilidade nas atualizações da Q-table. A região ($\alpha=0,1$; $\gamma=0,95$), usada como padrão neste estudo,

situa-se em zona de cooperação intermediária, equilibrando estabilidade e capacidade de capturar reciprocidade.

6. Discussão

6.1 Por Que a Cooperação Falha em Confrontos Simétricos?

Em QL x QL, ambos os agentes aprendem simultaneamente, criando um ambiente não-estacionário. O teorema do equilíbrio de Nash garante que (D,D) é um ponto fixo do jogo estático. Quando epsilon decai, a exploração diminui e os agentes ficam presos no atrator de traição. Qualquer ação C exploratória é punida pelo oponente, que aprendeu a retaliar, reforçando a preferência por D.

Esse resultado é consistente com a literatura de MARL: Sandholm e Crites (1996) já mostraram que Q-Learning tende a convergir para equilíbrios de Nash em jogos de matriz, mesmo quando esse equilíbrio é coletivamente ineficiente. A tragédia dos comuns surge organicamente do processo de aprendizado.

6.2 Por Que a Cooperação Emerge Contra TFT?

TFT cria um ambiente essencialmente estacionário e cooperativo: se o agente Q-Learning coopera, TFT coopera de volta (payoff 3,0); se trai, o TFT retalia (payoff 1,0). O problema de aprendizado torna-se quase supervisionado: a política ótima é claramente C.

A alta variância observada ($DP=0,111$) reflete que durante a fase de alta exploração (epsilon próximo a 1,0), traições aleatórias do agente Q-Learning desencadeiam ciclos de retaliação com TFT. A recuperação dessas traps depende da ordem estocástica das atualizações -- algumas sementes escapam, outras não. Esse fenômeno ilustra a sensibilidade das trajetórias de aprendizado às condições iniciais.

6.3 O Papel Paradoxal do Ruído

O achado de que ruído de 5% aumenta significativamente a cooperação em QL x QL (de 0,219 para 0,244; $p<0,001$) é contraintuitivo, mas tem interpretação teórica sólida. Ruído implementacional simula o TFT generoso de Nowak e May (1992): erros aleatórios quebram ciclos de traição mútua, permitindo que agentes testem ações C e, ocasionalmente, descubram equilíbrios mais lucrativos. Em biologia evolutiva, esse fenômeno é chamado de deriva genética cooperativa.

Em termos práticos, esse resultado sugere que em sistemas multi-agente reais -- onde erros de comunicação e implementação são inevitáveis -- o ruído moderado pode ser um aliado da cooperação, não um inimigo. Protocolos de negociação distribuída poderiam se beneficiar de mecanismos de aleatoriedade controlada.

6.4 Implicações para Design de Sistemas Multi-Agente

Os resultados têm implicações diretas para o design de sistemas de IA que interagem em ambientes competitivos:

- Inicialização cooperativa: começar com políticas colaborativas e reduzir exploração gradualmente favorece equilíbrios melhores.
- Seleção de oponentes de treinamento: treinar contra agentes cooperativos (como TFT) antes de ambientes hostis pode induzir heurísticas de cooperação generalizáveis.
- Horizonte de desconto: sistemas que precisam cooperar em longo prazo devem ser treinados com γ alto, que aumenta o valor da reciprocidade.
- Ruído moderado: um nível controlado de aleatoriedade no treinamento pode prevenir convergência para equilíbrios subótimos.

7. Conclusão

Este trabalho demonstrou empiricamente, com rigor estatístico, que agentes Q-Learning no Dilema do Prisioneiro Iterado convergem para o equilíbrio de Nash de traição mútua em confrontos simétricos, mas aprendem cooperação quando o ambiente recompensa reciprocidade. O tipo de oponente e o principal determinante da cooperação aprendida, com tamanho de efeito máximo ($r=1,0$). Memória adicional não altera o equilíbrio final, e ruído moderado paradoxalmente aumenta a cooperação ao quebrar ciclos de traição.

Esses achados conectam a teoria clássica dos jogos -- o folk theorem, o torneio de Axelrod, a dinâmica de replicadores -- com o paradigma moderno de aprendizado por reforço, mostrando que os mesmos princípios que explicam a evolução da cooperação biológica e social também regem o comportamento de agentes artificiais que aprendem.

Como próximos passos, sugere-se: (i) escalar para Deep Q-Network (DQN) com memória longa; (ii) introduzir dinâmica evolutiva com seleção proporcional ao fitness; (iii) expandir para jogos N-agentes em redes; e (iv) explorar mecanismos de comunicação pre-jogo.

Referências

- [1] Axelrod, R. & Hamilton, W.D. (1981). The evolution of cooperation. *Science*, 211(4489), 1390-1396.
- [2] Axelrod, R. (1984). *The Evolution of Cooperation*. Basic Books, New York.
- [3] Sandholm, T.W. & Crites, R.H. (1996). Multiagent reinforcement learning in the iterated prisoner's dilemma. *Biosystems*, 37(1-2), 147-166.
- [4] Nowak, M.A. & May, R.M. (1992). Evolutionary games and spatial chaos. *Nature*, 359, 826-829.
- [5] Watkins, C.J.C.H. & Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3-4), 279-292.
- [6] Sutton, R.S. & Barto, A.G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- [7] Fudenberg, D. & Maskin, E. (1986). The folk theorem in repeated games with discounting. *Econometrica*, 54(3), 533-554.
- [8] Nash, J. (1951). Non-cooperative games. *Annals of Mathematics*, 54(2), 286-295.